Détection de joueurs de football potentiellement sous-évalués sur le marché des transferts

Projet Neural Network and Deep Learning

Anaëlle Pollart

Juillet 2026

1. Introduction

1.1 Choix du domaine

Je suis fan de football depuis toute petite et suis ce sport très régulièrement, aussi bien les matchs que l'actualité autour des clubs. J'aimerais m'orienter vers ce domaine plus tard, donc ce projet était une belle occasion de faire quelque chose de concret en lien avec ma passion.
Chaque année, les clubs dépensent des sommes énormes pour recruter des joueurs. Parfois il y a de très bonnes surprises, comme un joueur acheté pas cher qui devient un titulaire indiscutable, et parfois des échecs coûteux. J'ai donc trouvé intéressant d'essayer de comprendre, avec des vraies statistiques et un modèle de Deep Learning, ce qui peut expliquer la valeur marchande d'un joueur et s'il est possible de repérer des profils dont la valeur estimée est supérieure à leur valeur actuelle. C'est un peu l'idée du "Moneyball" (popularisé au baseball, puis repris dans plusieurs sports) appliquée au football : utiliser les données en complément de la réputation, pour prendre de meilleures décisions de recrutement.

1.2 Contexte et objectif

La valeur marchande d'un joueur dépend en partie de ses statistiques de performance. Mais elle dépend aussi d'autres facteurs: réputation, âge, potentiel perçu par les recruteurs, situation contractuelle, médiatisation... Les cellules d'analyse de données de certains clubs professionnels essaient aujourd'hui de s'appuyer davantage sur les statistiques, pour compléter ce jugement humain. Le but est de repérer des opportunités de recrutement que la seule réputation ne permettrait pas de voir.
L'objectif de ce projet est de reproduire cette démarche à petite échelle. À partir du profil d'un joueur (âge, taille, poste, championnat...) et de ses statistiques sur une saison (matchs joués, buts, passes décisives...), un modèle de Deep Learning apprend à estimer sa valeur marchande "attendue". Il apprend cette relation à partir des profils et des valeurs des joueurs présents dans le jeu d'entraînement. Un écart important entre la valeur prédite et la valeur réelle ne prouve pas qu'un joueur est vraiment sous-évalué ou surévalué, car l'écart peut aussi venir d'informations que le modèle ne voit pas. Mais ça peut signaler un profil intéressant à regarder de plus près : un joueur dont la valeur prédite est beaucoup plus haute que sa valeur réelle est potentiellement sous-évalué, et inversement pour un joueur surévalué.
Techniquement, c'est un problème de régression : on prédit un nombre (la valeur marchande), pas une catégorie. Le modèle utilisé est un réseau de neurones dense (MLP). C'est une architecture adaptée à ce genre de données tabulaires, un tableau de chiffres avec une ligne par joueur. Les autres architectures vues en cours ne sont pas adaptées ici : un CNN suppose une structure spatiale (image), et un RNN une structure séquentielle, alors que chaque joueur est décrit par une seule ligne de statistiques agrégées sur la saison. Le MLP est donc l'architecture la plus naturelle pour ce type de données.

1.3 Plan du rapport

Ce rapport suit les grandes étapes d'un projet de Deep Learning : présentation des données (section 2), analyse exploratoire (section 3), préparation des données (section 4), modèles de référence et premier réseau de neurones (section 5), optimisation avec les techniques vues en cours (section 6), évaluation finale et interprétation critique des résultats (section 7), puis conclusion générale (section 8).

2. Données

Les données viennent du jeu « Football Data from Transfermarkt », disponible sur Kaggle. Ce jeu de données est construit à partir du site Transfermarkt, une référence dans le monde du football pour le suivi des valeurs marchandes. Il regroupe 12 tables reliées par un identifiant de joueur (player_id). Quatre d'entre elles sont utilisées ici :

- `players.csv` : profil de chaque joueur (poste, date de naissance, nationalité, club, championnat, valeur marchande, taille...), 48 380 joueurs et 26 colonnes.
- `appearances.csv` : une ligne par match joué, avec buts, passes décisives, minutes jouées et cartons, environ 1,89 million de lignes.
- `player_valuations.csv` : historique de la valeur marchande d'un joueur dans le temps, environ 656 000 lignes.
- `competitions.csv` : nom complet de chaque championnat, utile pour rendre les résultats plus lisibles.

Les autres tables (clubs, transferts, calendrier des matchs) n'apportaient pas d'information supplémentaire pertinente pour ce projet.

Point méthodologique important : la colonne highest_market_value_in_eur, qui correspond à la valeur marchande maximale atteinte par un joueur au cours de sa carrière, est volontairement exclue des variables d'entrée. Elle est trop proche de la valeur actuelle qu'on cherche à prédire. L'utiliser reviendrait presque à donner la réponse au modèle.

3. Analyse exploratoire des données

Avant de construire un modèle, il est important de bien comprendre les données. À quoi elles ressemblent, s'il y a des valeurs bizarres ou manquantes, et quelles variables semblent liées à la valeur marchande.

3.1 Distribution de la valeur marchande

Sur les 41 506 joueurs de players.csv dont la valeur marchande est renseignée, la distribution est très déséquilibrée. La majorité des joueurs ont une valeur relativement faible, tandis que quelques joueurs atteignent des montants très élevés, jusqu'à 200 millions d'euros. La médiane est de 275 000 €, alors que la moyenne atteint 1,5 million d'euros. Cet écart s'explique par la présence de quelques joueurs très chers, puisque la majorité des joueurs ont une valeur marchande inférieure à 500 000€.

Cette distribution pose un problème pour l'entraînement du modèle. Si la valeur marchande était utilisée directement en euros, les erreurs sur les joueurs les plus chers auraient beaucoup plus de poids que celles sur les autres joueurs. La cible est donc transformée avec un logarithme avant l'entraînement. Cette transformation réduit l'écart entre les petites et les grandes valeurs et rend l'apprentissage plus équilibré. À la fin, les prédictions sont reconverties en euros grâce à l'opération inverse, l'exponentielle.

3.2 Âge et valeur marchande

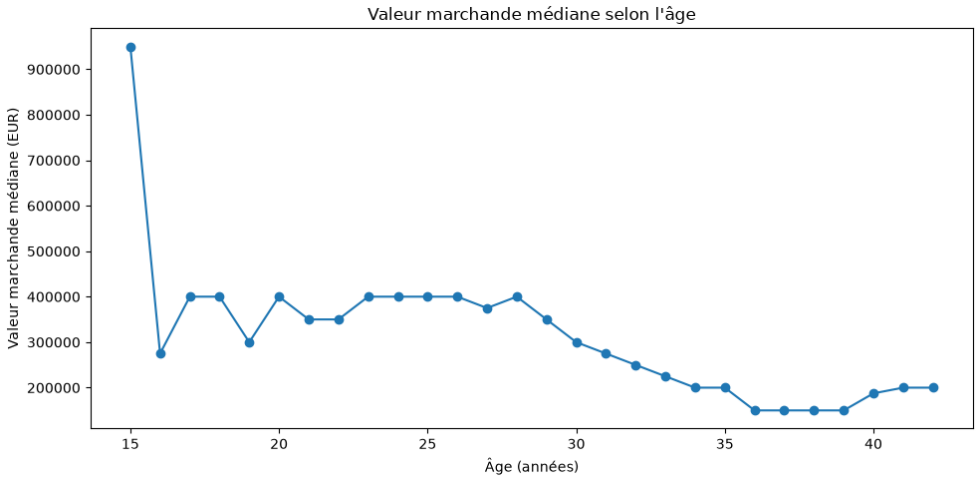


Figure 1 : Valeur marchande médiane selon l'âge.

La valeur marchande médiane reste stable entre 17 et 28 ans (300 000 à 400 000 €). Elle diminue ensuite régulièrement après 29 ans, ce qui correspond à la réalité du football : moins d'années de carrière restantes et risque de blessure plus élevé.

Le point isolé à 15 ans, très au-dessus du reste, ne doit pas être interprété comme une vraie tendance. Seulement deux joueurs de 15 ans ont une valeur renseignée, Linus Güther (1 M€) et Eirik Granaas (900 k€). C'est un échantillon trop petit pour être fiable.

Ce graphique montre surtout que la relation entre âge et valeur n'est pas une droite. Elle reste stable jusqu'à environ 28 ans, puis redescend. Une régression linéaire simple aurait du mal à bien représenter cette forme, ce qui justifie de tester également un modèle non linéaire (section 5).

3.3 Sélections en équipe nationale

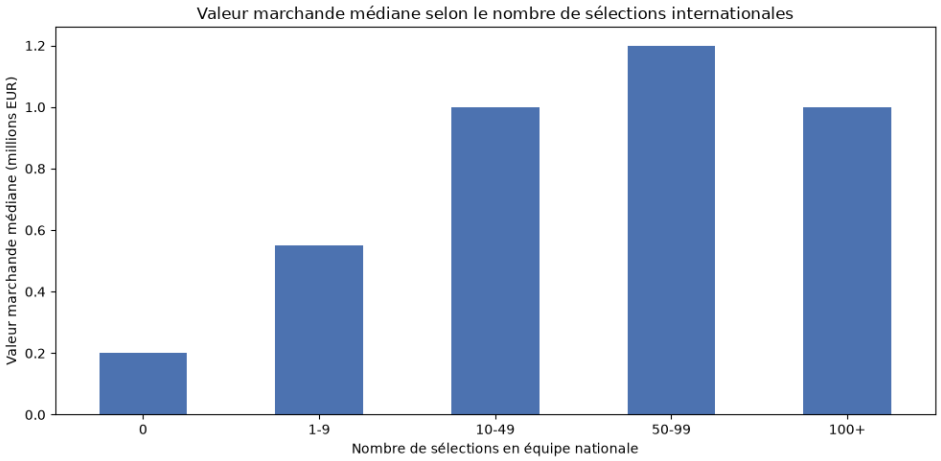


Figure 2 : Valeur marchande médiane selon le nombre de sélections internationales.

Plus un joueur a de sélections en équipe nationale, plus sa valeur médiane est élevée en général. L'écart peut atteindre environ 5 fois entre les joueurs jamais sélectionnés et les plus sélectionnés. Être régulièrement appelé en sélection peut être considéré comme un indicateur du niveau et de l'expérience du joueur, ce qui peut aussi se refléter dans sa valeur marchande.

La progression n'est pas parfaitement régulière : le groupe "50-99 sélections" dépasse légèrement le groupe "100+". Mais ces deux groupes contiennent peu de joueurs (794 et 152), donc leur médiane est plus sensible aux cas particuliers. Le nombre de sélections reste donc une variable utile, sans être suffisante à elle seule.

3.4 Valeur marchande selon le poste

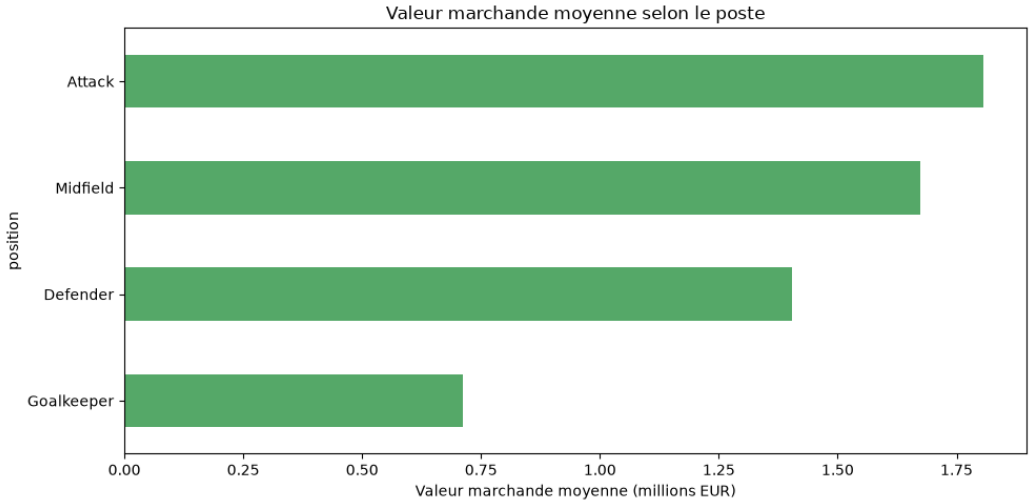


Figure 3 : Valeur marchande moyenne selon le poste.

Les attaquants ont la valeur moyenne la plus élevée (1,8 M€), suivis des milieux (1,7 M€) puis des défenseurs (1,4 M€). Les gardiens sont nettement les moins valorisés (0,7 M€). Cet écart peut notamment s'expliquer par le fait que les buts et les passes décisives sont des statistiques très visibles, principalement produites par les attaquants et les milieux offensifs. Les gardiens, eux, sont jugés sur d'autres critères (arrêts, sorties) qui ne sont pas disponibles ici (voir aussi 7.3).

Détail technique : ce graphique utilise la moyenne plutôt que la médiane. En médiane, attaquants, milieux et défenseurs sont exactement à égalité (300 000 € chacun). Les différences de moyenne viennent donc surtout des joueurs les plus chers de chaque poste. Le poste est gardé comme variable du modèle (encodage one-hot, section 4).

3.5 Cohérence de l'historique de valorisation

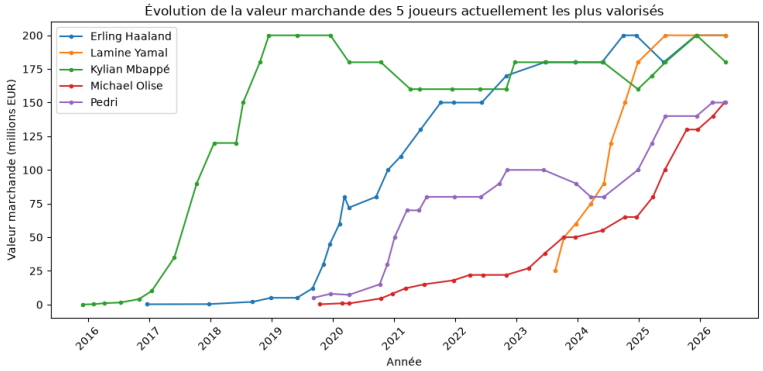


Figure 4 : Évolution de la valeur marchande des 5 joueurs actuellement les plus valorisés.

Ce graphique sert à vérifier la la cohérence générale des données avant de les utiliser. Les cinq joueurs affichés sont ceux à la valeur actuelle la plus haute : Haaland, Yamal, Mbappé, Olise, Pedri. Leurs courbes correspondent bien à l'évolution connue de leur carrière. Mbappé, par exemple, progresse fortement dès 2017, au moment de ses débuts remarqués à l'AS Monaco, avant son transfert au PSG. Yamal, lui, apparaît plus tardivement (25 M€ fin 2023) et grimpe très fort en 2024, ce qui correspond à sa percée médiatique lors de l'Euro 2024.

Cette cohérence avec des événements réels et connus est un contrôle de plausibilité rassurant. Mais il ne garantit pas à lui seul l'absence de doublons, de valeurs manquantes ou d'incohérences ailleurs dans les données.

3.6 Corrélations entre variables numériques

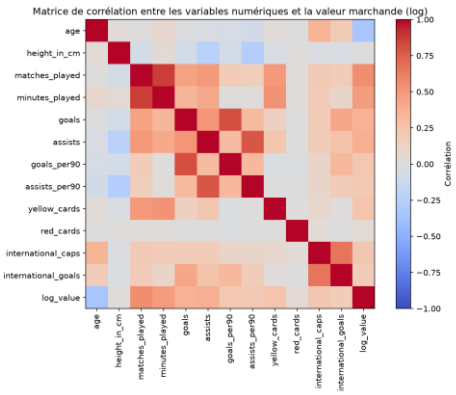


Figure 5 : Matrice de corrélation entre les variables numériques et la valeur marchande (échelle log).

Une matrice de corrélation montre à quel point chaque variable est liée linéairement à une autre. Proche de 1, les deux augmentent ensemble. Proche de -1, l'une augmente quand l'autre diminue. Proche de 0, il n'y a pas de lien évident.

Le résultat le plus marquant : le temps de jeu est la variable la plus corrélée à la valeur marchande. Le nombre de matchs joués (0,55) et les minutes jouées (0,48) dépassent les statistiques offensives brutes : les passes décisives (0,39) et les buts (0,36). Une explication possible : un joueur régulièrement titularisé a généralement la confiance de son club, et ça peut se refléter dans sa valeur. Mais cette corrélation ne prouve pas ce lien de cause à effet à elle seule. Fait intéressant, les statistiques ramenées à 90 minutes (buts/90 : 0,22 ; passes/90 : 0,21) sont moins corrélées que les totaux bruts. Dans ce dataset, le volume de jeu semble donc apporter davantage d'information sur la valeur marchande que l'efficacité calculée par minute.

L'âge est la seule variable nettement corrélée négativement (-0,34), ce qui est cohérent avec le déclin de valeur après 29 ans (section 3.2). La taille (0,00) n'a quasiment aucun lien linéaire avec la valeur marchande. Enfin, certaines variables sont logiquement corrélées entre elles : matchs et minutes jouées (0,87), buts et buts/90 (0,81). Cette redondance n'empêche pas leur utilisation dans un réseau de neurones, contrairement à une régression linéaire classique qui est plus sensible à la colinéarité. Mais elle explique pourquoi ces variables apportent une information proche l'une de l'autre au modèle.

4. Préparation des données pour la modélisation

Une fois les données comprises, il faut les transformer pour qu'elles puissent être utilisées par un modèle de Deep Learning. Cette section décrit les étapes de cette préparation, et pourquoi chaque choix a été fait.

4.1 Choix de la période de référence

Les statistiques de performance doivent être calculées sur une période précise. La saison 2025-2026 est choisie comme référence, car c'est la plus récente, et celle qui compte le plus de matchs et de joueurs suivis. Une saison de football va d'août à l'été suivant : un match joué en janvier 2026 fait donc partie de la saison 2025-2026.
Les statistiques de performance (matchs, minutes, buts, passes, cartons) viennent uniquement de cette saison, pas de l'historique complet de carrière. Le profil du joueur (âge, taille, sélections) reflète, lui, sa situation la plus récente. La valeur marchande cible est la dernière connue avant une date de référence, fixée à juillet 2026.

4.2 Calcul des statistiques de performance

La table appearances.csv contient une ligne par match. Il faut regrouper ces lignes par joueur, pour obtenir des totaux sur la saison : matchs, minutes, buts, passes, cartons. Les buts et passes sont aussi ramenés à 90 minutes, pour comparer plus facilement des joueurs ayant des temps de jeu différents, par exemple un titulaire et un remplaçant.
Un filtre écarte les joueurs ayant joué moins de 450 minutes, l'équivalent d'environ 5 matchs complets. En dessous, les statistiques par 90 minutes deviennent peu fiables : un seul but en 20 minutes donnerait une moyenne totalement irréaliste une fois ramené à 90 minutes. Après l'ensemble des filtres et des fusions présentés dans cette section, le dataset final contient 5 289 joueurs.

4.3 Valeur marchande de référence

player_valuations.csv contient plusieurs valeurs par joueur, une à chaque mise à jour de Transfermarkt, chacune datée. Cette table est utilisée plutôt que la colonne market_value_in_eur de players.csv, qui n'a pas de date associée : il est donc difficile de vérifier précisément si elle correspond à la période des statistiques de performance. Pour chaque joueur, seule la valeur la plus récente avant la date de référence est donc gardée. Cela permet d'utiliser une cible datée et aussi proche que possible de la période étudiée.

4.4 Fusion avec le profil du joueur

Les statistiques de performance sont fusionnées avec le profil du joueur (poste, âge, taille, sélections, championnat). Les valeurs manquantes de sélections sont remplacées par 0. Les tailles manquantes sont remplacées par la médiane des tailles connues, plutôt que de perdre ces joueurs.

4.5 Encodage du championnat

Le championnat est une variable catégorielle avec beaucoup de valeurs possibles. Pour éviter une colonne par championnat, seuls les 10 plus représentés sont gardés individuellement (Premier League, Liga, Serie A...). Les autres sont regroupés en "Autres". Chaque championnat retenu devient une colonne de 0 ou 1 (encodage one-hot), comme pour le poste. Ces 10 championnats sont choisis sur le dataset complet.

4.6 Cible et assemblage du dataset final

La cible est calculée en appliquant la transformation logarithmique (section 3.1) à la valeur marchande. Toutes les variables retenues sont ensuite rassemblées dans un seul tableau final : 5 289 joueurs, 27 variables explicatives.

4.7 Corrélations entre variables numériques

Une analyse de corrélation a été réalisée sur ce jeu de données final. Elle est présentée en détail en section 3.6, placée dans l'analyse exploratoire pour plus de clarté, même si elle est calculée à cette étape du pipeline.

4.8 Séparation train / validation / test

Le jeu de données est séparé en 70 % entraînement, 15 % validation et 15 % test. Le train set sert à entraîner les modèles, le validation set à choisir les meilleurs réglages (section 6), et le test set est réservé à l'évaluation finale (section 7). Le découpage est aléatoire plutôt que par date : l'objectif n'est pas de prédire l'avenir à partir du passé, mais d'estimer, à un instant donné, la relation entre performance et valeur marchande.

Les variables numériques sont normalisées, avec une moyenne à 0 et un écart-type à 1. Ça évite que des échelles très différentes (âge entre 15 et 40, minutes jusqu'à plusieurs milliers) ne perturbent l'apprentissage. Les statistiques de normalisation sont calculées uniquement sur l'entraînement, puis appliquées aux autres ensembles, pour éviter toute fuite d'information.

4.9 Une précaution : limiter les prédictions extrêmes

La cible est en échelle logarithmique. Revenir à des euros demande une exponentielle, qui amplifie fortement toute erreur. Une petite erreur en log peut devenir énorme une fois reconvertie. Une prédiction légèrement trop haute pourrait donc devenir irréaliste, par exemple atteindre plusieurs centaines de millions d'euros, ce qui fausserait toutes les métriques.

Par précaution, toute prédiction est donc plafonnée à la valeur maximale observée à l'entraînement, avant reconversion. Cette règle est appliquée de façon identique pour tous les modèles comparés. Une deuxième mesure est aussi calculée en plus de la MAE : l'erreur absolue médiane, moins sensible aux quelques cas extrêmes.

5. Modèles de référence et premier réseau de neurones

5.1 Pourquoi des baselines ?

Avant un modèle compliqué, il faut des points de comparaison simples, des "baselines". Sinon, impossible de savoir si un modèle plus complexe apporte vraiment quelque chose. Deux baselines sont utilisées ici.

La baseline triviale prédit systématiquement la valeur médiane du jeu d'entraînement, sans regarder les statistiques du joueur. C'est une baseline minimale et naïve, qui correspond à une prédiction constante.

La baseline linéaire est le réseau de neurones le plus simple possible : une seule couche, sans fonction d'activation. Ça équivaut à une régression linéaire classique. Elle utilise donc les vraies statistiques, mais seulement de façon linéaire.

5.2 Multi-Layer Perceptron (MLP)

Après avoir défini les deux baselines, un premier MLP est entraîné afin d'avoir un point de comparaison avec un réseau de neurones plus classique. L'architecture utilisée est volontairement simple : deux couches cachées de 64 neurones, puis une sortie à un seul neurone. Ce MLP est entraîné sans régularisation à ce stade. Le but est d'avoir un résultat de référence avant d'optimiser (section 6).

Modèle	MAE (validation)
Baseline triviale (médiane)	7,1 M€
Baseline linéaire	4,0 M€
MLP sans régularisation	4,9 M€

À cette étape, les modèles sont comparés uniquement sur le validation set. Le test set reste réservé à l'évaluation finale de la section 7.

Sur le validation set, le MLP sans régularisation obtient de meilleurs résultats que la baseline triviale, mais il fait moins bien que la baseline linéaire.

La transformation logarithmique de la cible et les variables utilisées rendent probablement une partie importante de la relation plus simple à modéliser. La baseline linéaire arrive donc déjà à représenter une grande partie de la relation entre les caractéristiques des joueurs et leur valeur marchande.

Le premier MLP contient deux couches de 64 neurones et possède beaucoup plus de paramètres que la baseline linéaire. Avec environ 3 700 joueurs dans le train set et sans régularisation, cette complexité supplémentaire ne permet pas forcément de mieux généraliser sur les données de validation.

Cela ne signifie pas que le Deep Learning n'est pas adapté au problème. Ce premier MLP sert de point de départ. La section suivante teste une architecture plus petite, de la régularisation, plusieurs optimiseurs et différents learning rates afin de trouver une configuration mieux adaptée au dataset.

6. Optimisation et amélioration

Cette section applique au MLP les techniques de régularisation et d'optimisation vues en cours. Le but est d'obtenir un modèle final plus performant et plus fiable.

6.1 Taille du réseau

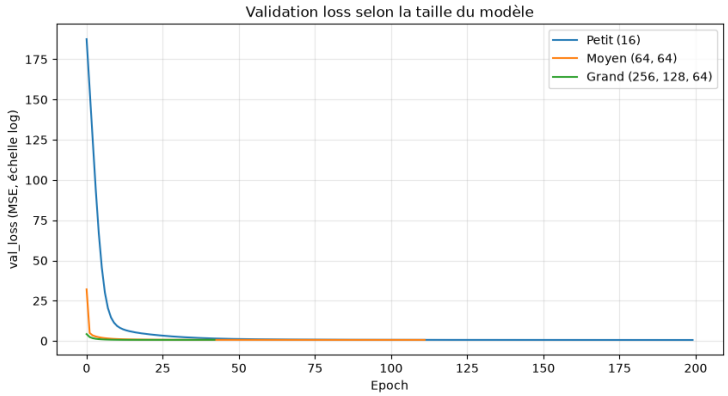


Figure 6 : Validation loss selon la taille du modèle.

Trois architectures sont comparées : petite (16 neurones), moyenne (64-64, celle de la section 5), grande (256-128-64). Le modèle "Petit" part d'une erreur plus élevée et met plus de temps à descendre. Cela peut venir de sa capacité plus limitée et d'un apprentissage plus progressif. Mais après une quarantaine d'epochs, les trois tailles arrivent à un niveau de validation loss proche.

Le modèle "Petit" (16 neurones) obtient à la fois la meilleure validation loss (0,615, epoch 200) et la meilleure MAE en euros (4,3 M€). Il devance "Moyen" (64-64 : 0,660, 4,5 M€) et "Grand" (256-128-64 : 0,678, 4,7 M€), qui font moins bien sur les deux critères. C'est cohérent avec la taille du jeu d'entraînement, environ 3 700 lignes : un réseau plus large a plus de paramètres à ajuster, mais pas plus de données pour les contraindre. Cette capacité supplémentaire n'apporte donc pas d'amélioration ici et peut rendre l'entraînement moins stable ou favoriser le sur-apprentissage. Le modèle "Petit" n'a pas déclenché l'arrêt anticipé avant la fin des 200 epochs. Cela signifie que la validation loss a encore connu des améliorations pendant l'entraînement, même si elles peuvent être faibles. C'est donc cette architecture qui est retenue pour la suite de l'optimisation (régularisation, optimiseur, learning rate).

6.2 Régularisation : L2 et Dropout

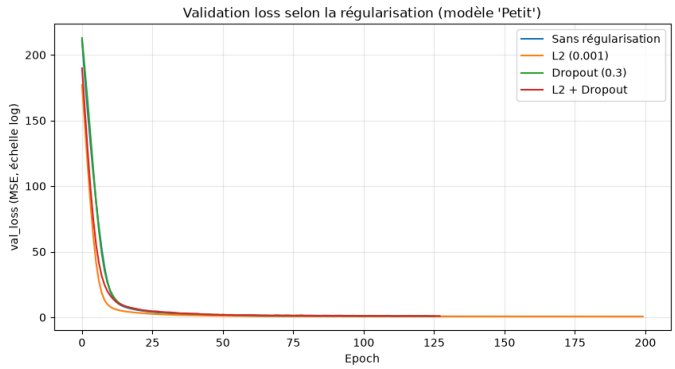


Figure 7 : Validation loss selon la régularisation (architecture « Petit »).

La régularisation sert à limiter le sur-apprentissage, c'est-à-dire que le modèle apprend "par cœur" les données d'entraînement au lieu de règles générales. Deux techniques sont testées sur l'architecture retenue en 6.1 (« Petit ») : la régularisation L2, qui pousse les poids à rester petits, et le Dropout, qui désactive aléatoirement 30 % des neurones à chaque étape pour rendre le réseau plus robuste. Quatre configurations sont comparées : sans régularisation, avec L2 seul, avec Dropout seul, et les deux combinés.

Sur cette architecture « Petit », le Dropout (seul ou combiné à L2) est clairement le plus mauvais en validation loss : autour de 0,92, contre 0,63 sans Dropout. Avec seulement 16 neurones sur une seule couche cachée, désactiver 30 % d'entre eux à chaque passage prive le réseau d'une bonne partie d'une capacité déjà limitée. La configuration « Sans régularisation » obtient la meilleure validation loss (0,628), tandis que « L2 seul » obtient la meilleure MAE en euros (4,0 M€ contre 4,4 M€). L'écart entre les deux reste toutefois faible. La régularisation L2 (0,001), sans Dropout, est donc retenue pour le modèle final : elle a la meilleure MAE tout en restant proche de la meilleure validation loss, sans les inconvénients du Dropout observés ici. Un EarlyStopping, présenté dans la section 6.4, est également utilisé.

6.3 Comparaison d'optimiseurs

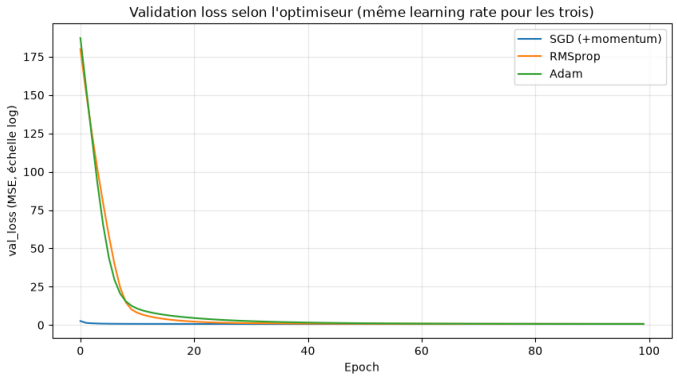


Figure 8 : Validation loss selon l'optimiseur, à learning rate identique (0,001).

L'optimiseur ajuste les poids du réseau à chaque étape d'entraînement. Trois optimiseurs sont comparés, sur l'architecture et la régularisation retenues jusqu'ici (« Petit » + L2). Ils utilisent le même learning rate (0,001) pour rester équitables : SGD avec momentum, RMSprop, et Adam.

La seed est réinitialisée avant chaque entraînement afin de limiter l'effet de l'initialisation. Les trois optimiseurs finissent tous par converger vers un niveau de validation loss très bas et proche, mais leurs trajectoires restent très différentes au départ. Adam et RMSprop partent d'une validation loss très élevée, autour de 190, et mettent une dizaine d'epochs à redescendre à un niveau raisonnable. SGD avec momentum, lui, reste bas et stable dès le premier epoch. Ces différences viennent du fonctionnement des optimiseurs et de la manière dont ils mettent à jour les poids. Cette seule expérience ne permet cependant pas d'expliquer précisément le pic observé pour Adam et RMSprop.

Cette comparaison reste surtout pédagogique : chaque optimiseur devrait normalement être réglé séparément, un même learning rate n'étant pas forcément optimal pour les trois. Adam est retenu pour la suite, car il finit par atteindre de bons résultats et qu'il est couramment utilisé pour entraîner les réseaux de neurones. Son learning rate est réglé dans la section suivante.

6.4 Choix du learning rate

Le learning rate contrôle la taille des pas de l'optimiseur. Trop grand, l'entraînement peut diverger. Trop petit, il devient très lent. Quatre valeurs sont testées pour Adam, avec la configuration retenue jusqu'ici, architecture « Petit » et régularisation L2 : 0,01 ; 0,005 ; 0,001 ; 0,0005.

Le choix ne se limite pas à la MAE de validation en échelle log. Cette métrique ne dit rien du comportement du modèle une fois reconverti en euros (section 4.9). Chaque candidat est donc aussi évalué avec son erreur en euros, MAE et RMSE, calculée sur le validation set uniquement, jamais sur le test set.

Learning rate	MAE valid. (log)	MAE valid. (€)	RMSE valid. (€)
0,01	0,637	4,8 M€	13,5 M€
0,005	0,611	4,0 M€	10,3 M€
0,001	0,601	4,0 M€	10,2 M€
0,0005	0,652	4,2 M€	11,3 M€

Le learning rate 0,001 obtient le meilleur résultat sur les trois critères à la fois : la meilleure MAE de validation en échelle log (0,601), la meilleure MAE en euros à égalité avec 0,005 (4,0 M€), et le meilleur RMSE (10,2 M€ contre 10,3 M€ pour 0,005). Les learning rates plus extrêmes, 0,01 et 0,0005, font clairement moins bien sur les trois critères, surtout en RMSE : 13,5 M€ et 11,3 M€, contre 10,2 M€ pour 0,001.

Le learning rate 0,001 est donc retenu pour le modèle final, avec l'architecture « Petit » et la régularisation L2 (0,001) retenues précédemment. Il obtient les meilleurs résultats globaux parmi les valeurs testées. Un EarlyStopping avec une patience de 15 epochs est également utilisé afin d'arrêter l'entraînement lorsque la validation loss ne s'améliore plus. L'option restore_best_weights=True permet de conserver les poids correspondant au meilleur résultat obtenu sur le validation set.

7. Interprétation des résultats

Cette section évalue le modèle final sur le test set, et interprète ce que ce résultat veut dire, au-delà du simple chiffre de MAE. Le test set n'a servi ni à l'entraînement ni au réglage d'aucun modèle précédent, puisque le choix du learning rate (6.4) s'est appuyé uniquement sur le validation set. Cette évaluation finale reste donc honnête. Mais un seul entraînement ne suffit pas pour savoir si un écart de MAE entre deux modèles est réel, ou s'il vient juste du hasard de l'initialisation des poids. C'est pour ça que chaque modèle à poids aléatoires (baseline linéaire, MLP sans régularisation, modèle final) est entraîné 5 fois avec des seeds différentes. La Figure 9 présente le détail des résultats obtenus pour chaque entraînement, tandis que la Figure 10 compare la MAE moyenne des quatre modèles.

Le Tableau 2 ci-dessous présente de son côté les métriques obtenues lors de l'entraînement initial du modèle final, notamment la MAE, l'erreur absolue médiane, le RMSE et le R^2.

Indicateur	Valeur	Ce que ça veut dire
MAE (test)	4,1 M€	en moyenne, le modèle se trompe de 4,1 M€ sur l'entrainement initial
Erreur absolue médiane	1,1 M€	pour la moitié des joueurs, l'erreur est sous 1,1 M€
RMSE	9,5 M€	erreur quadratique, plus sensible aux gros écarts
R^2 (échelle log)	0,720	le modèle explique environ 72 % de la variance de la cible après transformation logarithmique

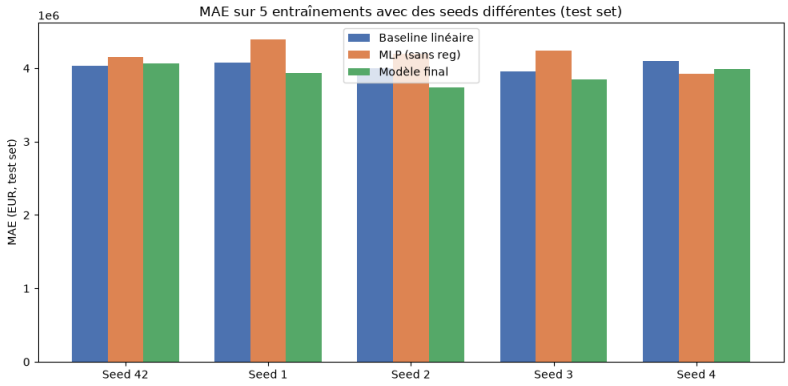


Figure 9 : MAE sur 5 entraînements avec des seeds différentes (détail par seed, test set).

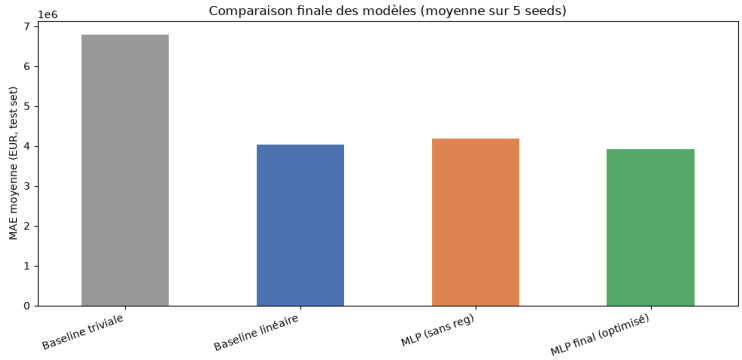


Figure 10 : MAE comparée des quatre modèles sur le test set (moyenne sur 5 seeds).

Sur une moyenne de 5 entraînements avec des seeds différentes, plutôt qu'une seule exécution, le modèle final obtient une MAE moyenne de 3,9 M€. C'est la MAE la plus faible parmi les trois modèles à poids aléatoires : il devance la baseline linéaire (4,0 M€) et le MLP sans régularisation (4,2 M€), et tous les trois devancent largement la baseline triviale (6,8 M€). L'optimisation apporte donc un léger gain moyen, assez cohérent d'un entraînement à l'autre. Ce gain reste modeste, environ 0,1 M€ de mieux que la baseline linéaire, et il n'a pas fait l'objet d'un test statistique formel. Une part importante de la relation entre les variables utilisées et la valeur marchande semble donc déjà pouvoir être représentée par un modèle linéaire.

L'écart entre la MAE du run unique (4,1 M€, seed 42, Tableau 2) et l'erreur médiane (1,1 M€) montre autre chose : ce résultat ponctuel est fortement tiré par un petit nombre de cas extrêmes. Pour la moitié des joueurs du test set, l'erreur de prédiction est en fait sous 1,1 M€. Mais quelques cas isolés, avec un écart de plusieurs dizaines de millions d'euros, pèsent lourd dans la moyenne.

7.1 Les cas les plus extrêmes

Le cas le plus extrême de tout le test set est un joueur considéré comme surévalué par le modèle : Pedri (FC Barcelone) a une valeur réelle de 150 M€, mais le modèle ne prédit que 38,3 M€, un écart de 111,7 M€. Du côté des joueurs potentiellement sous-évalués, le cas le plus marqué est Malick Thiaw (Newcastle United), prédit à 141,3 M€ contre une valeur réelle de 45 M€, soit -96,3 M€.
Des écarts aussi importants appellent quand même à la prudence : ils peuvent refléter un décalage entre les statistiques du joueur et sa valeur marchande, ou simplement une extrapolation du modèle en dehors de sa zone habituelle de prédiction. Dans cette exécution, aucune prédiction du test set ne dépasse le plafond de 200 M€. La plus haute, 141,3 M€ pour Malick Thiaw, garde même une marge confortable. Le plafonnement n'a donc pas modifié les métriques finales : il reste seulement une précaution pour d'éventuelles prédictions futures plus extrêmes.

7.2 Joueurs potentiellement sous-évalués et surévalués selon le modèle

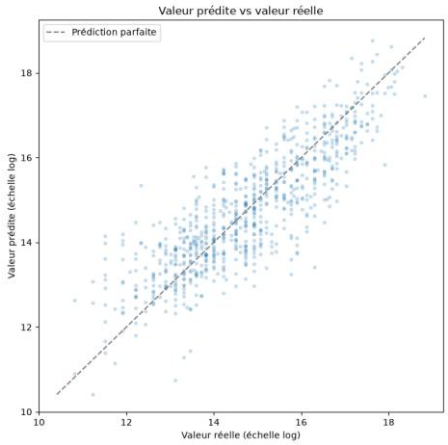


Figure 11 : Valeur prédite vs valeur réelle (échelle logarithmique) sur le test set.

Ce graphique compare, pour chaque joueur du test set, la valeur prédite à la valeur réelle. Plus un point est proche de la ligne pointillée (prédiction parfaite), plus la prédiction est bonne. La majorité des points sont assez proches de la ligne, ce qui est cohérent avec le R^2 de 0,72. Mais certains s'en éloignent nettement : ce sont les joueurs présentant les écarts les plus importants entre leur valeur réelle et leur valeur prédite.

Les 3 joueurs potentiellement les plus sous-évalués selon le modèle, sur le test set :

Joueur	Poste	Valeur réelle	Valeur prédite	Écart
Malick Thiaw	Défenseur	45,0 M€	141,3 M€	-96,3 M€
Nikola Milenković	Défenseur	28,0 M€	93,5 M€	-65,5 M€
Victor Froholdt	Milieu	50,0 M€	102,4 M€	-52,4 M€

Les 3 joueurs potentiellement les plus surévalués selon le modèle :

Joueur	Poste	Valeur réelle	Valeur prédite	Écart
Pedri	Milieu	150,0 M€	38,3 M€	+111,7 M€
Dean Huijsen	Défenseur	60,0 M€	7,5 M€	+52,5 M€
Matheus Cunha	Attaquant	75,0 M€	39,7 M€	+35,3 M€

Ces deux classements montrent bien ce que le modèle sait faire, et surtout ce qu'il ne sait pas faire. Il ne se base que sur la performance statistique et le profil du joueur pendant une saison, sans connaître le potentiel perçu par les recruteurs, la situation contractuelle, la médiatisation, ou l'effet d'un agent. Le classement des joueurs potentiellement surévalués en donne un bon exemple : on y retrouve de jeunes joueurs très prometteurs (Pedri, Dean Huijsen). Leur valeur intègre un pari sur l'avenir, que les statistiques d'une seule saison ne peuvent pas justifier seules. Ces classements doivent donc être lus comme des pistes de réflexion pour un recruteur, pas comme des recommandations d'achat certaines.

7.3 Limites et pistes d'amélioration

Ce projet a plusieurs limites, importantes à garder en tête pour bien interpréter ses résultats :

- Le filtre de temps de jeu minimum (450 minutes) écarte les joueurs les plus marginaux d'une équipe. Leur valeur est justement difficile à expliquer avec une saison incomplète, donc le modèle ne peut rien dire sur ce profil de joueurs.
- Les statistiques utilisées (buts, passes décisives) sont aussi peu adaptées aux gardiens de but. Leur performance se juge sur d'autres critères : arrêts, sorties, relances. Ça explique en partie pourquoi ce poste est probablement le moins bien modélisé.
- Le découpage aléatoire du jeu de données ne reproduit pas non plus un vrai cas d'usage de recrutement. Dans la réalité, un club utiliserait plutôt les statistiques de la saison en cours pour anticiper la valeur de la saison suivante. C'est un problème différent, plus proche d'une prédiction temporelle, que celui traité ici.
- Enfin, le modèle se base uniquement sur la performance sportive et le profil du joueur. Il n'intègre pas des éléments pourtant déterminants dans la réalité du marché des transferts, comme la situation contractuelle, la réputation, la médiatisation ou l'influence d'un agent. Il faut aussi rappeler que la valeur marchande Transfermarkt reste elle-même une estimation d'experts, pas un prix de transaction réel. Le modèle apprend donc à reproduire un jugement humain, avec ses propres biais possibles.

Plusieurs pistes permettraient d'améliorer ce projet dans une prochaine version : traiter les gardiens de but à part, avec des statistiques spécifiques à leur poste ; intégrer des informations contractuelles, comme la durée restante du contrat, pour mieux refléter la réalité du marché ; élargir la période de référence à plusieurs saisons passées, pour augmenter la taille du jeu d'entraînement, aujourd'hui limité à environ 3 700 joueurs ; systématiser la recherche d'hyperparamètres (recherche en grille ou aléatoire) plutôt qu'une comparaison manuelle de quelques valeurs, pour explorer plus largement les combinaisons possibles ; et utiliser une validation croisée (K-Fold) plutôt qu'un seul split validation/test, pour obtenir une estimation plus robuste de la performance du modèle.

8. Conclusion générale

Ce rapport présente un projet complet de détection de joueurs potentiellement sous-évalués sur le marché des transferts, des données brutes jusqu'à un modèle de Deep Learning évalué de façon critique. L'analyse exploratoire a permis de mettre en évidence plusieurs points clés : l'asymétrie de la valeur marchande, la relation en plateau puis en baisse entre l'âge et la valeur, l'importance du temps de jeu (plus corrélé à la valeur que les statistiques offensives brutes), et la cohérence des données de valorisation dans le temps. Un choix méthodologique clair a aussi été fait pour éviter toute fuite de données entre les variables d'entrée et la cible : la colonne highest_market_value_in_eur a été exclue.

La comparaison entre une baseline triviale, une baseline linéaire et un MLP optimisé montre que le modèle final obtient un gain moyen mais modeste par rapport à la baseline linéaire. Ce résultat est confirmé par une comparaison sur 5 entraînements plutôt qu'une seule exécution. Ça suggère qu'une part importante de la relation représentée par les variables retenues peut déjà être modélisée de façon linéaire. Les techniques d'optimisation et de régularisation vues en cours (taille du réseau, L2, Dropout, comparaison d'optimiseurs, réglage du learning rate, EarlyStopping) ont été comparées de façon concrète plutôt que choisies au hasard. Elles ont permis d'obtenir un classement de joueurs présentant les plus grands écarts entre leur valeur réelle et leur valeur prédite.